

基于注意力关系图的 NAD 算法

王小康¹

¹（东南大学网络空间安全学院 南京）

摘要 由于人工智能（AI）技术的快速发展，攻击者设计的后门攻击对深度神经网络（DNNs）的威胁日益增加。Yige Li 等人^[1]提出了一种新型防御框架——神经注意力蒸馏（Neural Attention Distillation, NAD），用于从已植入后门的 DNN 中消除后门触发器，并通过实验证明，针对 6 种先进的后门攻击，NAD 能够仅使用 5% 的干净训练数据有效清除后门触发器，且不会对干净样本的性能造成明显下降。尽管 NAD 能够有效地从 DNN 中清除后门触发器，但由于 NAD 仅利用相同阶数的注意力特征（即注意力图）进行后门防御，其攻击成功率（ASR）仍然不可忽略。本文基于注意力关系图对 NAD 方法进行改进，提出 NAD-im 算法，利用注意力关系图（ARG）^[2]充分挖掘不同阶数注意力特征之间的相关性。在知识蒸馏过程中，通过教师模型与学生模型间 ARG 的对齐，NAD-im 能够比 NAD 消除更多的后门触发器。综合实验结果表明，针对 3 种先进的后门攻击，NAD-im 相比于 NAD，虽然分类准确率相对有所下降，平均 0.48%，但攻击成功率相对降低高达 38.21%。

关键词 神经注意力蒸馏；注意力关系图；深度神经网络；后门攻击；后门防御

引言

随着人工智能（AI）技术的迅速发展，深度神经网络（DNNs）在各种安全关键领域的应用日益增多，例如自动驾驶、商业监控和医疗监测等。尽管 DNN 能够实现智能感知与控制，但它们也日益成为攻击者的主要目标。据报道，DNN 在生命周期的不同阶段容易受到潜在威胁的攻击^[3]。例如，由于训练数据存在偏差或模型出现过拟合/欠拟合，在测试阶段，某些对抗攻击对输入施加微小扰动即可误导 DNN，导致错误或意外的行为^[4]，从而可能引发灾难性后果。

此外，DNN 还易受另一类攻击——后门攻击的影响。近年来，由于后门攻击在实际场景中容易执行，因此受到了更多关注^{[5][6]}。直观而言，后门攻击旨在通过污染训练数据中的一小部分样本，使模型学习触发器与目标标签之间的强相关性。即使是像单像素或黑白棋盘^[5]这样简单的触发器，也可能使攻击者完全控制模型行为。

目前，主流的后门防御方法主要有两类：第一类是基于检测的方法，可识别训练过程中是否存在后门攻击。尽管这些方法在防止 DNN 遭受后门攻击方面表现良好，但它们无法修复已被植入后门触发器的模型。第二类是基于消除的方法，旨在通过净化带后门模型的恶意影响来消除后门触发器。NAD 则属于后者。需要注意的是，由于后门具有隐蔽性和不可感知性，完全净化带后门的 DNN 非常困难。因此，本文的目标是基于 NAD 进行改进，在不降低模型在干净

数据上分类准确率（ACC）的前提下，进一步降低带后门数据上的攻击成功率（ASR）。

神经注意力蒸馏被认为是非常有效的后门消除方法，其实现基于微调和蒸馏操作。受注意力转移（attention transfer）思想^[7]的启发，NAD 利用教师模型指导带后门的学生模型在一小部分干净数据上进行微调。需要指出的是，该教师模型是通过在完全相同的干净数据集上对同一学生模型进行进一步微调而得到的。通过将学生模型中间层的注意力特征与教师模型对应特征对齐，可以有效消除 DNN 中的后门触发器。在 NAD 中，注意力特征表示某一层所有神经元的激活信息。因此，DNN 内所有特征注意力的结合能够反映模型拓扑中最具判别力的区域。

尽管注意力机制本身可以作为衡量后门消除效果的重要指标，但 NAD 的实现方式却严重限制了注意力特征的表达能力，因为它在微调过程中仅比较相同层次的特征注意力，完全忽略了不同层级注意力特征之间的相关性^[8]。在微调过程中忽略这些显著特征，可能导致后门防御效果出现“断崖式”下降^[7]。

针对这一问题，本文基于注意力关系图对 NAD 进行改进。本文的主要贡献如下：

1、提出 NAD-improve 算法（以下简称 NAD-im）：注意力关系图能够充分反映不同层次注意力特征之间的相关性，将其与 NAD 结合，用于从 DNN 中消除更多后门触发器。

2、在多种后门攻击上进行了全面实验，验证 NAD-im 的有效性和效率。

1 相关工作

后门攻击：近年来，针对深度神经网络（DNN）的后门攻击在现实场景中层出不穷。典型的后门攻击通过在部分训练样本中注入特定的触发器模式（trigger pattern）实现，攻击形式分为带毒标签攻击（poisoned-label attack）和干净标签攻击（clean-label attack）。在测试阶段，只要输入含有该触发器的样本，即可操控模型预测结果，导致严重的安全隐患。为了在不显著降低干净样本准确率（ACC）的前提下尽可能提升攻击成功率（ASR），研究者们设计了种类繁多的后门触发器。现有后门攻击可分为两类：可感知的后门攻击和不可感知的后门攻击。尽管可感知的后门攻击对 DNN 具有显著影响，但由此改变的训练数据容易被发现。作为替代方案，不可感知的后门攻击在实际中更为常用。

后门防御：主流的后门防御方法主要可分为两类。第一类是基于检测的方法，这类方法可以在训练过程中识别 DNN 中的后门触发器，或通过过滤带后门的训练数据来消除后门攻击的影响。需要注意的是，现有的检测方法很少能够直接净化带后门的 DNN。第二类是基于消除的方法，这类方法通常基于有限的干净数据，通过微调带后门的 DNN 来消除后门触发器。尽管已有多种基于消除的方法被广泛研究，但至今尚无方法能够完全净化带后门的 DNN。大多数方法仍在从不同角度努力实现在降低 ASR 的同时维持甚至提升干净样本准确率（ACC）。

NAD-im 是考虑注意力特征相关性以消除 DNN 后门触发器的尝试。基于注意力关系图（ARGs）及相应的损失函数，NAD-im 能够显著降低 ASR，同时 ACC 几乎不下降。

知识蒸馏（Knowledge Distillation, KD）：知识蒸馏最早被提出用于将一个较大的模型或性能强大的教师模型集成压缩为一个轻量级的小模型^[10]。在该过程中，知识更丰富的模型被称为教师网络，而体积更小的模型则称为学生网络。特征图和注意力机制已

被大量工作证明在知识蒸馏中极具价值，可用于监督学生网络的训练^[11]。它们能够帮助学生网络学习到更高质量的中间表示，从而显著提升蒸馏效果并改善学生网络的最终性能^[7]。除模型压缩外，知识蒸馏还在诸多领域展现出潜力，例如对抗鲁棒性、多粒度唇语阅读以及数据增强^[12]等。

2 神经注意力蒸馏

与直接使用微调后的网络作为最终模型不同，NAD 将微调后的网络作为教师网络，并通过注意力蒸馏过程将其与原始带后门的网络（即学生网络）相结合。NAD 的目标是使对触发模式更敏感的神经元与仅对良性神经元更敏感的神经元对齐。接下来几小节中，将介绍 NAD 使用的注意力表示，并介绍注意力蒸馏过程中使用的损失函数。

2.1 注意力表示

给定一个深度神经网络（DNN）模型 F ，将第 l 层的激活输出记为 $F^l \in \mathbb{R}^{C \times H \times W}$ ，其中 C 、 H 、 W 分别表示激活特征图的通道数、高度和宽度。定义注意力算子 $\mathcal{A}$ ： $\mathbb{R}^{C \times H \times W} \rightarrow \mathbb{R}^{H \times W}$ ，将激活图映射为注意力表示。具体而言， $\mathcal{A}$ 将一个三维激活图 F 作为输入，并输出一个展平后的二维张量作为该通道维度的三种可能变换之一。NAD 遵循 Zagoruyko 和 Komodakis^[7]建议的注意力算子形式：

$$\mathcal{A}_{\text{sum}}(F^l) = \sum_{i=1}^C |F_i^l|; \quad (1)$$

$$\mathcal{A}_{\text{sum}}^p(F^l) = \sum_{i=1}^C |F_i^l|^p; \quad (2)$$

$$\mathcal{A}_{\text{mean}}^p(F^l) = \frac{1}{C} \sum_{i=1}^C |F_i^l|^p; \quad (3)$$

其中 F_i^l 表示第 i 个通道的激活图， $|\cdot|$ 是绝对值函数，且 $p > 1$ 。直观上， $\mathcal{A}_{\text{sum}}$ 反映了包括良性和




图 1 基于注意力关系图的 NAD 算法

后门神经元在内的所有激活区域。 $\mathcal{A}_{\text{sum}^p}$ 是 $\mathcal{A}_{\text{sum}}$ 的一种泛化形式, 通过 p 的阶数放大后门神经元与良性神经元之间的差异。简单来说, p 越大, 对激活最高区域的权重就越大。 $\mathcal{A}_{\text{mean}}$ 通过对所有激活区域取均值, 使后门神经元的激活中心与良性神经元的激活中心对齐。

2.2 注意力蒸馏损失

对于 ResNet, 我们在每个残差块之后使用所提出的注意力函数之一计算注意力表示。教师网络在整个蒸馏过程中保持固定。学生网络与教师网络在第 l 层的注意力图之间的蒸馏损失定义为:

$$\mathcal{L}_{\text{NAD}}(F_T^l, F_S^l) = \left\| \frac{\mathcal{A}(F_T^l)}{\|\mathcal{A}(F_T^l)\|_2} - \frac{\mathcal{A}(F_S^l)}{\|\mathcal{A}(F_S^l)\|_2} \right\|_2 \quad (4)$$

其中 $\|\cdot\|_2$ 是 L_2 范数, $\mathcal{A}(F_T^l) / \mathcal{A}(F_S^l)$ 分别是教师/学生网络计算得到的注意力图。值得一提的是, 注意力图的归一化对成功的蒸馏至关重要^[7]。

2.3 总体训练损失

总体训练损失是交叉熵 (CE) 损失与所有 K 个残差组上的神经元注意力蒸馏 (NAD) 损失之和的组合:

$$\mathcal{L}_{\text{total}} = \mathbb{E}_{(x,y) \sim D} \left[\mathcal{L}_{\text{CE}}(F_S(x), y) + \beta \cdot \sum_{l=1}^K \mathcal{L}_{\text{NAD}}(F_T^l(x), F_S^l(x)) \right] \quad (5)$$

其中 $\mathcal{L}_{\text{CE}}(\cdot)$ 度量学生网络的分类误差, D 是用于微调的干净数据子集, l 是残差组的索引, β 是一个控制注意力蒸馏强度的超参数。在进行注意力蒸馏之前, 需要先准备好一个教师网络。我们在相同的干净子集 D 上微调带后门的网络以获得教师网络。

3 基于注意力关系图的 NAD

3.1 注意力关系图 (Attention Relation Graph, ARG)

受文献[8]中实例关系图 (instance relation graph) 的启发, 注意力关系图旨在显式建模不同层级注意力特征之间的知识变换关系 (knowledge transformation relation), 从而为后门防御提供更稳健的防御结构对齐机制, 使含后门的学生模型在蒸馏过程中向干净的教师模型逼近。

与基于图像实例回归精度构建的实例关系图不同, ARG 直接建立在模型不同层级的注意力特征之上。对于给定的输入样本, 模型的 ARG 完全由其多层的注意力特征构造而成。

假设: 在少量干净数据上微调得到的教师模型具有良性的知识结构, 其注意力关系图能够完整反映不同层级注意力特征之间的相关性。因此, 在知识蒸馏过程中, 本文以教师模型的 ARGs 作为指导, 通过对齐含后门学生模型的 ARGs 与其在教师模型中的对

应部分, 来引导对含后门学生模型的微调。

给定输入样本, 模型的注意力关系图可建模为一个完全图, 形式化地表示为二元组: $G = (N, \varepsilon)$; 其中 N 为节点集合, ε 为边集合。 N 中的每个节点对应某一特定层级的注意力特征, ε 中的每条边则表示一对节点 (即两个不同层级的注意力特征) 之间的相似性。

3.2 ARG 节点

给定深度神经网络模型 M 以及输入样本 X , 定义模型第 p 个卷积层的特征图为 $F^p = M^p(X)$, 该特征图具有通道、高、宽三个维度的激活张量。注意力提取操作 $\mathcal{A}_M$ 将三维特征图 F^p 转换为展平为二维注意力特征张量 T^p 。令 C 、 H 、 W 分别表示输入张量的通道数、高度和宽度, 则注意力提取操作可形式化为如下函数: $\mathcal{A}_M: \mathbb{R}^{C \times H \times W} \rightarrow \mathbb{R}^{H \times W}$;

具体定义为:

$$\mathcal{A}_M(F^p) = \frac{1}{C} \sum_{i=1}^C |F_i^p(X)|^2 \quad (6)$$

其中 C 为特征图 F^p 的通道数, F_i^p 表示 F^p 的第 i 个通道。对 F^p 施加 $\mathcal{A}_M$ 操作后, 即可得到 F^p 的注意力特征, 将其称为第 p 阶 ARG 节点。假设模型 M 共具有 k 个卷积特征图, 则基于 $\mathcal{A}_M$ 可构造节点集合: $\mathcal{N} = \{T_M^1, T_M^2, \dots, T_M^p, \dots, T_M^k\}$ 。实际实现中, 为兼顾效果与效率, 仅使用 N 的一个子集来构建注意力关系图。

3.3 ARG 边

在已得到节点集合后, 进一步构建完全图, 其中边集合:

$$\varepsilon = \bigcup_{i=1}^k \bigcup_{j=1}^k \varepsilon_i^j \quad (7)$$

用于刻画模型 M 中不同阶注意力特征之间的相关性, e^{ij} 表示连接第 i 阶节点 T_M^i 与第 j 阶节点 T_M^j 的边。定义边权函数 $E_M: \varepsilon \rightarrow \mathbb{R}$, 其中 $E_M^{ij} = E_M(e^{ij})$ 表示两个注意力特征 T_M^i 与 T_M^j 之间的欧氏距离。假设 T_M^i 与 T_M^j 的最大空间尺寸为 $h \times w$ 。令 $\Gamma_{ij}(Y)$ 为自适应空间对齐函数, 将任意注意力特征 Y 转换为尺寸固定为 $h \times w$ 的二维特征 Y' 。边权 E^{ij} 的计算公式为:

$$E_{M_{ij}} = \left\| \Gamma_{ij}(T_M^i) - \Gamma_{ij}(T_M^j) \right\|_2 \quad (8)$$

该距离越小, 说明对应两层的注意力分布越相似, 其在干净知识结构中的功能关联性越强。

3.4 ARG 嵌入

为便于将学生模型 ARG 与教师模型的 ARG 对

齐, 本文使用 ARG 嵌入, 即通过图嵌入方式将整个 ARG 的结构信息压缩为一个向量。由于嵌入向量能够高度概括图的语义特征, 因此可用于显式刻画教师模型与学生模型之间 ARG 的知识依赖关系。设 C 和 S 分别为教师模型和学生模型。基于第 p 阶注意力特征分别构建教师与学生的 ARG 嵌入向量 (即 R_C^p 和 R_S^p), 具体公式如下:

$$R_C^p = \sigma(W_C^p \cdot \psi(T_C^p)), \quad R_S^p = \sigma(W_S^p \cdot \psi(T_S^p)) \quad (9)$$

其中, $\psi(\cdot)$ 为自适应平均池化操作, $\sigma(\cdot)$ 为激活函数 (本文采用 ReLU), W_C^p 和 W_S^p 分别为教师模型和学生模型第 p 阶注意力特征对应的可学习线性变换参数, 用于在蒸馏过程中实现特征对齐。

通过比较教师模型与学生模型的嵌入向量, 我们能够捕捉学生节点与教师整体节点之间的相关性。在本文中, 将该相关性向量 β_S^p 定义为教师所有节点对当前第 p 阶学生节点的加权关联程度, 即:

$$\beta_S^p = \text{soft max} \left(R_S^{p\top} \cdot w_1^b \cdot R_C^1, \dots, R_S^{p\top} \cdot w_p^b \cdot R_C^p, \dots, R_S^{p\top} \cdot w_k^b \cdot R_C^k \right) \quad (10)$$

其中 w_i^b 为可学习的双线性权重, 用于在蒸馏过程中显式建模不同阶注意力特征之间的底层关联关系^[9]。该设计使得学生模型在微调时不仅关注同阶特征对齐, 还能动态感知与教师模型所有层级的结构化相关性, 从而实现更彻底的后门擦除

3.5 ARG 蒸馏损失

ARG 蒸馏损失 $\mathcal{L}_G$ 定义为教师 ARG 与学生 ARG 之间的差异。它从三个不同的结构视角刻画教师 ARG G_S 和学生 ARG G_C 之间的差异: i) 节点差异, 表示注意力特征在节点对上的差异总和; ii) 边差异, 刻画边对之间的距离差异总和; iii) 嵌入差异, 表示加权学生-教师节点对在嵌入向量上的差异。为了从不同的结构视角反映这些差异, 本文分别定义了三种损失, 即 ARG 节点损失 $\mathcal{L}_N$ 、ARG 边损失 $\mathcal{L}_E$ 和 ARG 嵌入损失 $\mathcal{L}_{Em}$ 。由于节点和边的权重顺序不同, ARG 边损失能够进一步增强教师模型与学生模型 ARG 之间的对齐。ARG 节点损失函数定义为:

$$\mathcal{L}_N(N_S, N_C) = \frac{1}{k} \sum_{i=0}^k \left\| \frac{T_C^i}{\|T_C^i\|_2} - \frac{T_S^i}{\|T_S^i\|_2} \right\|_2 \quad (11)$$

ARG 节点损失本质上是一种模仿损失, 能够使学生在像素层面对其教师模型对应的注意力特征进行对齐。ARG 边损失表示两个边集合之间的差异, 计算方式为:

$$\mathcal{L}_E(E_S, E_C) = \frac{1}{C_k^2} \sum_{i=1}^{k-1} \sum_{j=i+1}^k \|E_C^{ij} - E_S^{ij}\|_2^2 \quad (12)$$

其中 C_k^2 为组合数公式。在 ARG 对齐过程中, 学生模型的注意力特征需要从教师模型不同的注意力特征中学习知识。然而, 仅仅依靠 ARG 节点损失与边损失的组合无法充分挖掘教师模型与学生模型注意力特征之间的结构依赖关系。为了实现此类知识学习, 还需要基于关系向量的 ARG 嵌入损失, 其定义为:

$$\mathcal{L}_{Em}(T_C, T_S) = \sum_{i=1}^k \sum_{j=1}^k \beta_S^{ij} \|\Gamma_{ij}(T_C^i) - \Gamma_{ij}(T_S^i)\|_2 \quad (13)$$

基于上述三种损失, 定义 ARG 蒸馏损失 $\mathcal{L}_G$ 以在知识蒸馏过程中实现精确的 ARG 对齐, 公式为:

$$\mathcal{L}_G(G_S, G_C) = \mathcal{L}_N + \mathcal{L}_E + \mathcal{L}_{Em} \quad (14)$$

3.6 蒸馏总体损失

NAD-im 方法基于知识蒸馏。为了在蒸馏过程中实现 ARG 的对齐, 定义后门 DNN 的总体损失函数为:

$$\mathcal{L}_{\text{overall}} = \mathcal{L}_{CE} + \mathcal{L}_G \quad (15)$$

其中, $\mathcal{L}_{CE}$ 表示后门 DNN 预测结果与对应目标值之间的交叉熵损失。

4 实验

在本章中, 本文评估了 NAD 方法及其改进版本 NAD-im 的有效性。NAD-im 基于注意力关系图对蒸馏过程进行了增强, 以更好地捕捉中间层特征间的依赖关系, 从而提升对后门触发器的擦除效果。本章首先描述实验设置, 然后呈现原 NAD 方法与 NAD-im 在三种后门攻击 (BadNets、Trojan、Sig) 下的表现, 并进行比较。然后, 本章分析了基于 BadNets 攻击下, 不同干净数据比例 (1%、5%、10%、20%) 对原 NAD 方法与 NAD-im 防御效果的影响, 并对两者的表现进行对比。所有实验均在 CIFAR-10 数据集上进行, 使用 WideResNet-16-1 (WRN-16-1) 架构, 与原 NAD 论文^[1]保持一致。

4.1 实验设置

1、软硬件环境: 3050Ti 4GB; NVIDIA Tesla T4 32GB; pytorch。

Table 1. Defense Performance Comparison
表 1 防御效果对比

后门攻击	原始		NAD		NAD-im	
	ASR	ACC	ASR	ACC	ASR	ACC
BadNets	100.00	85.66	2.37	83.69	1.90	83.20
Trojan	99.43	83.72	2.21	82.23	2.89	81.79
SIG	99.94	83.10	3.83	82.64	0.41	82.37
平均	99.79	84.16	2.80	82.85	1.73	82.45
差值	--	--	↓ 96.99	↓ 1.31	↓ 98.06	↓ 1.71

2、数据集与模型：

使用 CIFAR-10 数据集，该数据集包含 50,000 张训练图像和 10,000 张测试图像，涵盖 10 个类别。在后门防御场景中，本文假设防御者可访问一小部分干净训练数据（默认 5%，即 2,500 张图像；其他比例包括 1%（500 张）、10%（5,000 张）和 20%（10,000 张））。后门学生模型和教师模型均基于 WRN-16-1，在污染数据上预训练。教师模型通过在干净子集上微调后门模型获得，与原 NAD 方法一致。

3、后门攻击：

本文针对三种代表性后门攻击进行评估：

BadNets^[5]：一种污染标签攻击，使用简单补丁作为触发器。

Trojan^[13]：一种动态触发器攻击，使用 Trojan 图案作为触发器。

SIG^[14]：一种信号注入攻击，使用隐形噪声或信号模式作为触发器。

4、后门防御：

NAD 与改进后的 NAD-im。

因 NAD 原论文已经充分证实了 NAD 算法在后门攻击防御方面的优越性（对比标准微调（Standard finetuning），Fine-pruning^[15]，MCR^[16]），本文不再进行 NAD 与其他后门防御算法的对比，仅针对 NAD 与 NAD-im 展开对比，以此来见证 NAD-im 做出了哪些提升，这也是本文的目标。

为确保比较的公平性，所有方法均使用相同的 5% 干净训练数据进行微调或净化，模拟防御者数据有限的现实场景，并使用相同的训练超参数和数据增强技术。教师模型（用于 NAD/NAD-im）通过在相同干净子集上独立微调后门模型获得。

5、评估指标：

攻击成功率（Attack Success Rate, ASR）：定义为模型在带触发器测试样本上的目标标签预测准确率。

干净准确率（Clean Accuracy, ACC）：定义为模型在干净测试样本上的准确率。

本文使用 PyTorch 框架实现，训练使用 SGD 优化器，默认使用 5% 的干净数据。所有结果均为多次运行的平均值，以确保可靠性。

4.2 不同后门攻击下的防御效果对比

基于注意力关系图，本文提出了 NAD-im 改进方法。该方法在蒸馏过程中引入注意力关系图，以更好地捕捉中间层特征间的结构化依赖关系，从而增强学生网络对后门触发器的清除能力。具体实现中，本文在学生模型的注意力表示中对教师网络的特征图形状进行采样（如[torch.Size([16, 32, 32]), torch.Size([32, 16, 16]), torch.Size([64, 8, 8])]），并通过额外的关系约束优化蒸馏损失，使学生网络的注意力分布更接近干净教师网络。

为全面评估 NAD-im 的有效性，本文在 5% 干净训练数据（即 CIFAR-10 训练集的 2,500 张图像）条件下，对三种典型后门攻击（BadNets、Trojan 和 SIG）进行了防御实验，并与原始 NAD 方法进行了对比。表 1 报告了原始后门模型（无防御）以及两种防御方法在最高 ACC 对应 epoch 下的性能指标。

从表 1 可以看出，原始 NAD 已在三种攻击上将平均 ASR 从 99.79% 大幅降低至 2.80%，同时干净准确率（ACC）仅下降 1.31%，这与原论文^[1]报道的结果一致，验证了本文复现的可靠性。相比之下，NAD-im 进一步将平均 ASR 降低至 1.73%，较原始

NAD 下降了 38.21%（相对下降），平均 ACC 仅额外下降 0.40%，表明改进方法在保持干净性能的前提下显著提升了后门擦除能力。具体而言：

在 BadNets 攻击下，NAD-im 将 ASR 从 2.37% 进一步降低至 1.90%，ACC 基本相当，体现了注意力关系图对可见补丁触发器的精细抑制效果。

在 Trojan 攻击下，NAD-im 的 ASR 略高于 NAD（2.89% vs. 2.21%），但仍远低于原始模型，且 ACC 差距仅为 0.44%，处于可接受范围。

在 SIG 攻击（隐形正弦信号触发器）下，NAD-im 表现出最显著的改进，将 ASR 从 3.83% 大幅降低至

0.41%，下降幅度达 89.30%，这表明注意力关系图在处理隐蔽、分布式噪声触发器时具有更强的鲁棒性，能够有效打破模型对信号模式的异常依赖。

总体而言，NAD-im 在三种攻击上的平均 ASR 下降幅度达到 98.06%，优于原始 NAD 的 96.99%，特别是在隐形攻击场景下优势更为明显。这一结果验证了注意力关系图能够为蒸馏过程提供更丰富的结构化监督信号，从而更彻底地擦除后门触发器对网络注意力的影响。

4.3 不同干净数据比例的影响

本文进一步基于 BadNets 攻击测试了不同干净数据比例（1%、5%、10%、20%）对 NAD-im 防御效果的影响，并与原 NAD 算法进行对比。实验中，所有其他超参数保持一致，包括学习率调度、优化器设

Table 2. Defense Performance under Different Clean Data

干净数据比例	Ratios			
	NAD		NAD-im	
	ASR	ACC	ASR	ACC
1%	10.60	82.16	4.80	80.80
5%	2.37	83.69	1.90	83.20
10%	2.16	85.32	1.90	84.08
20%	1.64	86.39	2.01	85.26

置和数据增强策略，以确保比较的公平性。表 2 报告了两种方法在不同干净数据比例下，最高 ACC 对应 epoch 的性能指标。

从表 2 可以看出，随着干净数据比例的增加，两种方法的干净准确率（ACC）均呈现稳步上升趋势，这符合预期：更多的干净样本为模型提供了更充分的正常特征学习机会，从而缓解了微调过程中的灾难性遗忘现象。同时，攻击成功率（ASR）整体上逐渐下降，表明后门触发器的残留影响被进一步抑制。

具体分析如下：

在极低数据比例（1%）下，原 NAD 的 ASR 仍高达 10.60%，ACC 为 82.16%，说明仅凭借极少量干净样本，原始注意力蒸馏难以完全对齐学生网络与干净教师网络的中间层表示，导致后门路径部分保留。相比之下，NAD-im 将 ASR 大幅降低至 4.80%（下降 54.72%），尽管 ACC 略有牺牲（下降 1.36%），但仍保持在可接受水平。这表明注意力关系图在数据极度稀缺场景下提供了更强的结构化监督信号，能够更有效地打破模型对触发器模式的依赖。

在 5%和 10%数据比例下，NAD-im 持续表现出更低的 ASR（分别为 1.90%），较原 NAD 分别下降约 20%和 12%，同时 ACC 差距小于 1%，验证了改进方

法在常规防御场景（少量干净数据可用）下的优越性。

当干净数据比例达到 20%时，两者 ASR 均降至 2%附近，原 NAD 略优（1.64% vs 2.01%），且 ACC 也更高（85.26% vs. 86.39%）。这表明在数据充足情况下，原始 NAD 已能实现较彻底的后门擦除，而 NAD-im 的额外关系约束可能引入轻微过拟合，但整体性能仍然优秀。

总体而言，NAD-im 在低数据比例（1%~10%）场景下表现出显著优势，平均 ASR 较原 NAD 降低约 30%，说明 NAD-im 适用于防御者仅能获取极少量可信数据的实际应用场景。随着数据比例增加，两种方法的性能差距逐渐缩小，并均趋近于干净模型的上限。这一结果进一步证实了注意力关系图的引入提升了方法的数据效率和鲁棒性，为后门防御在资源受限环境下的部署提供了更可靠的方案。

结论

本文提出了一种基于注意力关系图的神经注意力蒸馏改进方法 NAD-im，旨在进一步增强深度神经网络对后门攻击的防御能力。通过引入注意力关系图（ARG），NAD-im 能够显式捕捉不同层级注意力特征之间的结构化依赖关系，并在知识蒸馏过程中通过教师与学生 ARG 的对齐，实现更彻底的后门触发器擦除。相较于原始 NAD 方法，NAD-im 在保持蒸馏效率的同时，显著提升了防御鲁棒性。

实验结果表明，在 CIFAR-10 数据集上针对 BadNets、Trojan 和 SIG 三种典型后门攻击，相对于原 NAD，NAD-im 将平均攻击成功率（ASR）从 2.80%降低至 1.73%，下降幅度高达 38.21%（相对下降），特别是在隐形攻击如 SIG 下，ASR 下降达 89.30%。同时，干净准确率（ACC）平均仅下降 0.40%，验证了方法的有效性和实用性。此外，在不同干净数据比例（1%~20%）下的测试显示，NAD-im 在低干净数据比例场景下表现出更强的适应性，平均 ASR 降低约 30%，为资源受限环境下的后门防御提供了可靠方案。尽管 NAD-im 取得了显著改进，但仍存在一定局限性，如在数据充足时可能引入轻微过拟合，以及对特定触发器类型的敏感性差异。这些结果突显了注意力关系图在提升后门防御数据效率方面的潜力，并为未来 DNN 安全研究提供了思路。

参考文献

- [1] Li Y, Lyu X, Koren N, et al. Neural attention distillation: Erasing backdoor triggers from deep neural networks[J]. arXiv preprint arXiv:2101.05930,

- 2021.
- [2] Xia J, Wang T, Ding J, et al. Eliminating backdoor triggers for deep neural networks using attention relation graph distillation[J]. arXiv preprint arXiv:2204.09975, 2022.
- [3] Yunfei Song, Tian Liu, Tongquan Wei, Xiangfeng Wang, Zhe Tao, and Mingsong Chen. FDA3 : Federated defense against adversarial attacks for cloud-based iiot applications. *IEEE TH*, 17:7830–7838, 2021.
- [4] Nicholas Carlini and David Wagner. Towards evaluating the robustness of neural networks. In *IEEE S&P*, pages 39–57, 2017.
- [5] Tianyu Gu, Brendan Dolan-Gavitt, and Siddharth Garg. Badnets: Identifying vulnerabilities in the machine learning model supply chain. *IEEE Access*, 7:47230–47244, 2019.
- [6] Xinyun Chen, Chang Liu, Bo Li, Kimberly Lu, and Dawn Song. Targeted backdoor attacks on deep learning systems using data poisoning. arXiv preprint arXiv:1712.05526, 2017.
- [7] Nikos Komodakis and Sergey Zagoruyko. Paying more attention to attention: improving the performance of convolutional neural networks via attention transfer. In *ICLR*, 2017.
- [8] Yufan Liu, Jiajiong Cao, Bing Li, Chunfeng Yuan, Weiming Hu, Yangxi Li, and Yunqiang Duan. Knowledge distillation via instance relationship graph. In *CVPR*, pages 7096–7104, 2019.
- [9] Hamed Pirsiavash, Deva Ramanan, and Charles C Fowlkes. Bilinear classifiers for visual recognition. In *NIPS*, 2009.
- [10] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. In *NeurIPS*, 2014.
- [11] Byeongho Heo, Minsik Lee, Sangdoo Yun, and Jin Young Choi. Knowledge transfer via distillation of activation boundaries formed by hidden neurons. In *AAAI*, 2019.
- [12] Hessam Bagherinezhad, Maxwell Horton, Mohammad Rastegari, and Ali Farhadi. Label refinery: Improving imagenet classification through label progression. In *ICCV*, 2018.
- [13] Yingqi Liu, Shiqing Ma, Yousra Aafer, Wen-Chuan Lee, Juan Zhai, Weihang Wang, and Xiangyu Zhang. Trojaning attack on neural networks. In *NDSS*, 2018b.
- [14] Mauro Barni, Kassem Kallas, and Benedetta Tondi. A new backdoor attack in cnns by training set corruption without label poisoning. In *ICIP*, 2019.
- [15] Kang Liu, Brendan Dolan-Gavitt, and Siddharth Garg. Fine-pruning: Defending against backdooring attacks on deep neural networks. In *RAID*, 2018a.
- [16] Pu Zhao, Pin-Yu Chen, Payel Das, Karthikeyan Natesan Ramamurthy, and Xue Lin. Bridging mode connectivity in loss landscapes and adversarial robustness. In *ICLR*, 2020a.