

AWP 算法复现及改进

王小康¹

¹（东南大学网络空间安全学院 南）

摘要 近年来，提升深度神经网络对抗对抗样本鲁棒性的研究发展迅速。其中，对抗训练被认为是最具前景的方法之一，其核心思想是通过在对抗扰动样本上进行训练，从而使输入空间的损失函数景观（即损失对输入变化的敏感性）趋于平坦。然而，在对抗训练过程中，权重空间的损失函数景观（即损失对模型参数变化的敏感性）的行为却鲜有系统性的研究。Wu 等人^[1]从一个新的视角出发，对权重损失景观进行了深入分析，发现权重损失景观的平坦性与模型的鲁棒泛化间隙之间存在显著相关性，并进一步观察到，多种已有的、被广泛认可的对对抗训练改进策略在本质上都隐式地促进了权重损失景观的平坦化。基于上述观察，他们提出了一种简单而有效的方法——对抗权重扰动（AWP），用于显式地正则化权重损失景观的平坦性。该方法在传统对抗训练框架中引入了一种双重扰动机制，即同时对输入和模型权重施加对抗扰动。大量实验结果表明，AWP 能够显著改善权重损失景观的平坦性，并且可以无缝集成到多种现有的对抗训练方法中，从而进一步提升模型的对抗鲁棒性。本文对 AWP 方法进行了系统复现，并在此基础上探索了若干改进方案，包括分层对抗权重扰动（Layer-wise AWP）与渐进式对抗权重扰动（Progressive AWP）。实验结果表明，这些改进方法在当前实验设置下未能在鲁棒性能上显著优于原始 AWP 方法，但其训练过程稳定，整体性能与原方法几乎一致，验证了 AWP 框架在不同变体下的可行性与鲁棒性。

关键词 对抗权重扰动；对抗训练；分层对抗权重扰动；渐进式对抗权重扰动；

尽管深度神经网络（DNN）已在众多领域中得到广泛部署，例如计算机视觉、语音识别以及自然语言处理，但它们很容易被精心设计的对抗样本所欺骗，从而产生错误的预测。随着 DNN 在潜在高风险场景中的日常应用，确保其安全性（例如，提高其对对抗样本的鲁棒性）变得越来越重要。

为此，已经涌现出多种防御技术来提升 DNN 的对抗鲁棒性。在这些防御方法中，对抗训练（Adversarial Training, AT）^[2]是最有效且最有前途的方法之一，它不仅证明了在适度鲁棒性下的可行性，而且迄今为止在全面攻击下直接整合了对抗样本的训练过程，以求解如下优化问题：

$$\min_{\mathbf{w}} \rho(\mathbf{w}), \text{ where } \rho(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \max_{\|\mathbf{x}_i - \mathbf{x}_i'\|_p \leq \epsilon} \ell(f_{\mathbf{w}}(\mathbf{x}_i'), y_i) \quad (1)$$

其中， n 为训练样本数量， $\mathbf{x}_i'$ 为以自然样本 $\mathbf{x}_i$ 为中心、 L_p 范数有界的 ϵ -球内的对抗样本， $f_{\mathbf{w}}$ 为权重为 $\mathbf{w}$ 的 DNN， $\ell(\cdot)$ 为标准分类损失（例如，交叉熵（CE）损失），而 $\rho(\mathbf{w})$ 被称为“对抗损失”，遵循 Madry 等人^[3]的定义。公式（1）表明，对抗训练通过限制输入扰动时的损失变化（即平坦化输入损失景观）来获得一定程度的鲁棒性，但其鲁棒性仍远未达到满意的程度，因为巨大的鲁棒泛化差距，例如，基于 PreAct ResNet-18 在 CIFAR-10 上的对抗训练仅能达到 43%

的测试鲁棒性，即使它已在 200 个 epoch 后实现了 84% 的训练鲁棒性。其鲁棒泛化差距达到 41%，这与标准训练（仅使用自然样本）的标准泛化差距始终低于 10% 的情况形成鲜明对比。因此，如何缓解鲁棒泛化差距已成为提升对抗训练鲁棒性的关键改进方向。

回顾标准训练场景中，权重损失景观是一种广泛用于表征标准泛化差距的指标^[4]，然而，在对抗训练下的相关探索却相对较少，其中 Prabhu 等人^[5]和 Yu 等人^[6]尝试使用预生成的对抗本来探索权重损失景观，但未能得出预期的结论。Wu 等人^[1]探索了在对抗训练下使用在线生成的对抗本来探究权重损失景观，并发现了权重损失景观的平坦度与鲁棒泛化差距之间存在强烈的关联。几个近期的工作通过早期停止、TRADES、MART 和 RST 等方法，均隐式地平坦化了权重损失景观，从而缩小了鲁棒泛化差距。受此启发，Wu 等人^[1]提出了一种显式的权重损失景观正则化方法，称为对抗权重扰动（Adversarial Weight Perturbation, AWP），以直接约束对抗训练中权重损失景观的平坦度。不同于随机扰动^[7]，AWP 注入最强的最差情况权重扰动，形成了一种双重扰动机制（即输入和权重均被对抗扰动）并融入对抗训练框架。AWP 具有通用性，可轻松集成到现有的对抗训练方法中，几乎不增加额外开销。

在此基础上,本文对 AWP 方法进行了复现,并进一步探索了若干基于权重扰动粒度与调度策略的改进方案,包括分层对抗权重扰动(Layer-wise AWP)与渐进式对抗权重扰动(Progressive AWP)。实验结果表明,在本文所采用的模型结构与数据集下,这些改进方法在鲁棒性能上未能显著优于原始 AWP,但整体训练过程稳定,性能与原方法几乎一致,验证了 AWP 框架在不同变体下的可扩展性与适用性。

本文围绕对抗权重扰动这一近期提出的对抗训练方法展开研究,系统复现了其核心算法与实验流程,并在此基础上对权重扰动策略进行了若干探索性改进。本文的主要贡献可总结如下:

1) 复现了 AWP 对抗训练方法

本文基于标准对抗训练框架,在 CIFAR-10 数据集上复现了 AWP 方法的训练流程与实验配置,实现了输入扰动与权重扰动相结合的双重对抗机制,并验证了 AWP 在提升模型对抗鲁棒性方面的有效性,为后续研究提供了可复现的实现基础。

2) 探索并实现了分层对抗权重扰动策略。

针对原始 AWP 采用全局权重扰动的特点,本文尝试按照网络层级对权重扰动进行细化控制,在不改变原始训练框架的前提下,实现了分层对抗权重扰动,并对其训练稳定性与鲁棒性能进行了实验分析。

3) 提出并实现了渐进式对抗权重扰动策略。

为缓解权重扰动在训练初期可能带来的不稳定问题,本文设计了一种渐进式权重扰动调度方案,使扰动强度随训练过程逐步增强,并在统一实验设置下对其效果进行了验证。

4) 通过系统实验对不同权重扰动策略进行了对比与分析。

本文在相同网络结构与攻击配置下,对标准对抗训练、原始 AWP 以及两种改进策略进行了系统对比。实验结果表明,尽管 Layer-wise AWP 与 Progressive AWP 在当前实验条件下未能显著超越原始 AWP,但相关实验为理解权重扰动机制的作用边界提供了有价值的实证分析。

1 相关工作

1.1 对抗防御

自对抗样本被发现以来,已开发出许多防御方法来降低此类安全风险,例如防御蒸馏、特征挤压、输入去噪、对抗检测、梯度正则化以及对抗训练。其中,对抗训练已被证明是最有效的方法^[8]。基于对抗训练,又引入了许多新技术来进一步提升其性能。

1) TRADES^[9]优化了对抗风险的上界,该上界是

自然准确率与鲁棒准确率之间的权衡:

$$\rho^{\text{TRADES}}(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \left\{ \text{CE}(f_{\mathbf{w}}(\mathbf{x}_i), y_i) + \beta \cdot \max \text{KL}(f_{\mathbf{w}}(\mathbf{x}_i) \| f_{\mathbf{w}}(\mathbf{x}_i')) \right\} \quad (2)$$

其中 KL 为 Kullback-Leibler 散度, CE 为交叉熵损失, β 为控制自然准确率与鲁棒准确率权衡的超参数。

2) MART^[10]将误分类样本的显式区分融入作为对抗风险的正则化项:

$$\rho^{\text{MART}}(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \left[\text{BCE}(f_{\mathbf{w}}(\mathbf{x}_i'), y_i) + \lambda \cdot \text{KL}(f_{\mathbf{w}}(\mathbf{x}_i) \| f_{\mathbf{w}}(\mathbf{x}_i')) \cdot (1 - [f_{\mathbf{w}}(\mathbf{x}_i')]_{y_i}) \right] \quad (3)$$

其中, $[f_{\mathbf{w}}(\mathbf{x}_i')]_{y_i}$ 表示输出向量 $f_{\mathbf{w}}(\mathbf{x}_i')$ 的第 y_i 个元素,且 $\text{BCE}(f_{\mathbf{w}}(\mathbf{x}_i'), y_i) = -\log([f_{\mathbf{w}}(\mathbf{x}_i')]_{y_i}) - \log(1 - \max_{k \neq y_i} [f_{\mathbf{w}}(\mathbf{x}_i')]_k)$ 。

3) 基于半监督学习(SSL)^[11]的方法利用额外的无标签数据。首先,它们通过在有标签数据上训练一个自然模型来为无标签数据生成伪标签。然后,将对抗损失 $\rho(\mathbf{w})$ 应用于基于有标签和无标签数据训练鲁棒模型:

$$\rho^{\text{SSL}}(\mathbf{w}) = \rho^{\text{labeled}}(\mathbf{w}) + \lambda \cdot \rho^{\text{unlabeled}}(\mathbf{w}) \quad (4)$$

其中 λ 是无标签数据的权重。 $\rho^{\text{labeled}}(\mathbf{w})$ 和 $\rho^{\text{unlabeled}}(\mathbf{w})$ 通常采用相同的对抗损失。例如,Carmon 等人^[11]中的 RST 使用 TRADES 损失,而 Wang 等人^[10]中的半监督 MART 使用 MART 损失。

1.2 鲁棒泛化

与标准泛化(在自然样本上)相比,在对抗样本上训练 DNN 以实现鲁棒泛化特别困难,并且通常具有显著更高的样本复杂度,同时需要更多的数据。在对抗训练中,存在两种类型的损失景观:

1) 输入损失景观,即损失相对于输入的变化。

它描述了训练样本附近损失的变化。对抗训练(AT)通过在对抗扰动样本上进行训练来显式平坦化输入损失景观,而其他方法则通过梯度正则化、曲率正则化以及局部线性正则化来实现这一点。这些方法在训练速度上较快,但仅能达到与 AT 相当的鲁棒性。

2) 权重损失景观,即损失相对于权重的变化。

它揭示了模型权重周围损失景观的几何特性。与标准训练场景不同,在标准训练中众多研究已揭示了权重损失景观与其标准泛化差距之间的关联,而在对抗训练中这种关联是否存在仍处于探索阶段。Prabhu 等人^[5]尝试在对抗训练中建立这种关联,但由于权重损失景观表征不准确而未能成功。

Wu 等人^[1]则从一个新的视角表征权重损失景观,并识别出权重损失景观与鲁棒泛化差距之间存在清晰的关系。

2 权重损失景观与鲁棒泛化差距的关联

在本节中，首先描述 Wu 等人^[1]提出的一种新的权重损失景观表征方法，然后从两个视角对其进行探究：1) 在对抗训练的学习过程中；2) 在不同对抗训练方法之间；从而得出权重损失景观与鲁棒泛化差距之间存在清晰的相关性。

Wu 等人^[1]通过绘制当权重 $\mathbf{w}$ 沿随机方向 $\mathbf{d}$ 以幅度 α 移动时对抗损失的变化来可视化权重损失景观：

$$g(\alpha) = \rho(\mathbf{w} + \alpha \mathbf{d}) = \frac{1}{n} \sum_{i=1}^n \max_{\|\mathbf{x}_i - \mathbf{x}_i'\|_p \leq \epsilon} \ell(f_{\mathbf{w}+\alpha \mathbf{d}}(\mathbf{x}_i'), y_i) \quad (5)$$

其中 $\mathbf{d}$ 从高斯分布中采样，并通过滤波器归一化

$$d_{l,j} \leftarrow \frac{d_{l,j}}{\|d_{l,j}\|_F} \mathbf{w}_{l,j} \quad (d_{l,j} \text{ 是 } \mathbf{d} \text{ 的第 } l \text{ 层第 } j \text{ 个滤波器,}$$

$\|\cdot\|_F$ 表示 Frobenius 范数) 来消除 DNN 的尺度不变性。

对抗损失 ρ 通常通过交叉熵损失来近似计算。这里，我们为当前扰动模型 $f_{\mathbf{w}+\alpha \mathbf{d}}$ 使用在线生成的对抗样本（通过 PGD 攻击），然后计算其交叉熵损失。与先前工作的关键区别在于可视化过程中所使用的对抗样本。Prabhu 等人^[5]和 Yu 等人^[6]在原始模型 $f_{\mathbf{w}}$ 上使用一组固定的预生成对抗本来进行可视化，这会由于源模型（原始模型 $f_{\mathbf{w}}$ ）与目标模型（当前扰动模型 $f_{\mathbf{w}+\alpha \mathbf{d}}$ ）之间的不一致性而严重低估对抗损失。由于 $\mathbf{d}$ 是随机选择的，Wu 等人^[1]重复了 10 次使用不同 $\mathbf{d}$ 的可视化，其形状相似且稳定。因此，该可视化方法是有效的，可用于表征权重损失景观，并在此基础上仔细探究权重损失景观与鲁棒泛化差距之间的关联。

对抗训练学习过程中的关联：Wu 等人^[1]通过实验得出权重损失景观的平坦度在训练过程中与鲁棒泛化差距高度相关。

不同对抗训练方法之间的关联：Wu 等人^[1]使用几种最先进的对抗训练方法训练 PreAct ResNet-18，如 TRADES、MART、RST 以及带早期停止的 AT（AT-ES）。与标准 AT 相比，所有方法均具有更小的鲁棒泛化差距和更平坦的权重损失景观。尽管这些最先进方法使用各种技术来提升对抗鲁棒性，但它们均隐式地平坦化了权重损失景观。从而在实现更小泛化差距的方法中，也能观察到更平坦的权重损失景观。这一观察与训练过程中的一致，证实了权重损失景观与鲁棒泛化差距存在强烈的相关性。

为什么需要权重损失景观？

如前所述，对抗训练已通过在对抗样本上训练来优化输入损失景观的平坦度。然而，如何生成对抗样本是通过在每个样本上注入输入扰动来获得最高的对抗损失，这是一种样本级的“局部”最差情况，并

未考虑对多个样本的整体影响。DNN 的权重可以影响所有样本的损失，从而可以扰动以获得模型级的“全局”最差情况（最高对抗损失过所有样本）。权重扰动可以作为输入扰动的良好补充。此外，在扰动权重上进行优化（即，即使在权重添加扰动时损失仍保持较小）可以导致平坦的权重损失景观，从而进一步缩小鲁棒泛化差距。

3 对抗权重扰动

在本节中，介绍 Wu 等人^[1]提出对抗权重扰动（Adversarial Weight Perturbation, AWP），以通过注入最差情况权重扰动来显式平坦化权重损失景观。如上所述，为了提升测试鲁棒性，需要同时关注训练鲁棒性以及由权重损失景观平坦度带来的鲁棒泛化差距。因此，我们的目标是：

$$\min_{\mathbf{w}} \{ \rho(\mathbf{w}) + [\rho(\mathbf{w} + \mathbf{v}) - \rho(\mathbf{w})] \} \rightarrow \min_{\mathbf{w}} \rho(\mathbf{w} + \mathbf{v}) \quad (6)$$

其中 $\rho(\mathbf{w})$ 为公式（1）中的原始对抗损失， $\rho(\mathbf{w} + \mathbf{v}) - \rho(\mathbf{w})$ 用于表征权重损失景观的平坦度，而权重扰动 $\mathbf{v}$ 需要被仔细选择。

3.1 权重扰动

与常用的随机权重扰动（采样随机方向）不同，Wu 等人^[1]提出对抗权重扰动（AWP），沿着使对抗损失急剧增加的方向。那就是：

$$\min_{\mathbf{w}} \max_{\mathbf{v} \in \mathcal{V}} \rho(\mathbf{w} + \mathbf{v}) \rightarrow \min_{\mathbf{w}} \max_{\mathbf{v} \in \mathcal{V}} \frac{1}{n} \sum_{i=1}^n \max_{\|\mathbf{x}_i - \mathbf{x}_i'\|_p \leq \epsilon} \ell(f_{\mathbf{w}+\mathbf{v}}(\mathbf{x}_i'), y_i) \quad (7)$$

其中 $\mathcal{V}$ 为扰动 $\mathbf{v}$ 的可行区域。与对抗输入扰动类似，AWP 也在 $f_{\mathbf{w}}$ 周围的一个小区域内注入权重上的最差情况。请注意，对 $\mathbf{v}$ 的最大化依赖于整个样本集（至少是批次样本），以使整体损失（而非单个样本损失）最大化，因此这两个最大化问题是不可交换的。

在确定权重扰动方向后，需要决定注入多少扰动。与对抗输入上的固定值约束不同，我们使用相对于第 l 层权重 $\mathbf{w}_l$ 的相对大小来限制权重扰动 $\mathbf{v}_l$ ：

$$\|\mathbf{v}_l\| \leq \gamma \|\mathbf{w}_l\| \quad (8)$$

其中 γ 是对权重扰动大小的约束。使用相对大小约束权重扰动的原因有两个方面：1) 权重的数值分布因层而异，因此不可能使用固定值约束不同层的权重；2) 存在权重上的尺度不变性，例如，当使用非线性 RELU 时，如果将一层权重乘以 10，并在下一层除以 10，网络保持不变。

3.2 优化

一旦确定了权重扰动的方向和大小，Wu 等人^[1]

提出一种算法来优化公式 (7) 中的双重扰动对抗训练问题。对于两个最大化问题, 循环生成对抗样本 $\mathbf{x}_i'$ 并同时经验性地使用 PGD 更新权重扰动 $\mathbf{v}$ 。基于 AWP 的标准 AT 过程, 称为 AT-AWP, 其流程如下:

输入扰动: 使用 PGD 攻击在 $f_{\mathbf{w}+\mathbf{v}}$ 上生成对抗样本 $\mathbf{x}_i'$:

$$\mathbf{x}_i' \leftarrow \Pi_{\epsilon}(\mathbf{x}_i + \eta_1 \text{sign}(\nabla_{\mathbf{x}_i} \ell(f_{\mathbf{w}+\mathbf{v}}(\mathbf{x}_i), y_i))) \quad (9)$$

其中 $\Pi(\cdot)$ 是投影函数, 第一迭代时 $\mathbf{v}$ 为 0。

权重扰动: 基于生成的对抗样本 $\mathbf{x}_i'$ 计算对抗权重扰动:

$$\mathbf{v} \leftarrow \Pi_{\gamma} \left(\mathbf{v} + \eta_2 \frac{\nabla_{\mathbf{v}} \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}+\mathbf{v}}(\mathbf{x}_i'), y_i)}{\left\| \nabla_{\mathbf{v}} \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}+\mathbf{v}}(\mathbf{x}_i'), y_i) \right\|} \|\mathbf{w}\| \right) \quad (10)$$

其中 m 是批次大小, 且 $\mathbf{v}$ 是逐层更新的。类似于生成对抗样本 $\mathbf{x}_i'$ 通过 FGSM (单步) 或 PGD (多步), $\mathbf{v}$ 也可以通过单步或多步方法求解。随后, 我们可以交替生成 $\mathbf{x}_i'$ 和计算 $\mathbf{v}$ 若干迭代 A 。对于 A 的一个迭代和 $\mathbf{v}$ 的单步 (默认设置) 已足以获得良好的鲁棒性提升。模型训练。最后, 我们使用 SGD 更新扰动模型 $f_{\mathbf{w}+\mathbf{v}}$ 的参数。请注意, 在优化景观上的扰动点损失后, 我们应再次返回中心点以进行下一次启动。因此, 实际参数更新如下:

$$\mathbf{w} \leftarrow (\mathbf{w} + \mathbf{v}) - \eta_3 \nabla_{\mathbf{w}+\mathbf{v}} \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}+\mathbf{v}}(\mathbf{x}_i'), y_i) - \mathbf{v} \quad (11)$$

AT-AWP 算法伪代码:

AT-AWP 算法

输入: 网络 $\mathbf{w}$, 训练数据 $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, 批次大小 m , 学习率 η_3 , PGD 步长 η_1 , PGD 步数 K_1 , AWP 约束 γ , AWP 步长 η_2 , AWP 步数 K_2 , 交替迭代次数 A

输出: 鲁棒模型 $f_{\mathbf{w}}$

1: for $t=0$ to $T-1$ do

2: for $a=0$ to $A-1$ do

3: for $i=1, \dots, m$ (并行) do

4: $\mathbf{x}_i' \leftarrow \mathbf{x}_i + \epsilon \delta$, 其中 $\delta \sim \text{Uniform}(-1, 1)$

5: for $k=1, \dots, K_1$ do

6: $\mathbf{x}_i' \leftarrow \Pi_{\epsilon}(\mathbf{x}_i' + \eta_1 \text{sign}(\nabla_{\mathbf{x}_i'} \ell(f_{\mathbf{w}+\mathbf{v}}(\mathbf{x}_i'), y_i)))$

7: endfor

8: endfor

9: for $k=1, \dots, K_2$ do

10: $\mathbf{v} \leftarrow \Pi_{\gamma} \left(\mathbf{v} + \eta_2 \frac{\nabla_{\mathbf{v}} \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}+\mathbf{v}}(\mathbf{x}_i'), y_i)}{\left\| \nabla_{\mathbf{v}} \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}+\mathbf{v}}(\mathbf{x}_i'), y_i) \right\|} \|\mathbf{w}\| \right)$

11: endfor

12: endfor

13: $\mathbf{w} \leftarrow (\mathbf{w} + \mathbf{v}) - \eta_3 \nabla_{\mathbf{w}+\mathbf{v}} \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}+\mathbf{v}}(\mathbf{x}_i'), y_i) - \mathbf{v}$

14: endfor

3.3 理论分析

Wu 等人^[1]还从理论角度提供了 AWP 为何有效的观点。基于 PAC-Bayes 界在对抗训练中的先前工作, 令 $\ell(\cdot, \cdot)$ 为 0-1 损失, 则:

$$\rho(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \max_{\|\mathbf{x}_i - \mathbf{x}_i'\|_p \leq \epsilon} \ell(f_{\mathbf{w}}(\mathbf{x}_i'), y_i) \in [0, 1] \quad (12)$$

给定一个“先验”分布 P (高斯分布在权重上的常见假设为零均值), 分类器的预期误差在抽取 n 个训练数据后至少以概率 $1-\delta$ 有界:

$$\mathbb{E}_{(\mathbf{x}_i, y_i)_{i=1}^n, \mathbf{u}} [\rho(\mathbf{w} + \mathbf{u})] \leq \rho(\mathbf{w}) + \{\mathbb{E}_{\mathbf{u}} [\rho(\mathbf{w} + \mathbf{u})] - \rho(\mathbf{w})\} + 4\sqrt{\frac{1}{n} KL(\mathbf{w} + \mathbf{u} \| P) + \ln \frac{2n}{\delta}} \quad (13)$$

遵循 Neyshabur 等人^[4], 我们选择 $\mathbf{u}$ 为每个方向上的零均值球形高斯扰动, 方差为 σ^2 , 并将扰动方差相对于其幅度设置为 $\sigma = \alpha \|\mathbf{w}\|$, 这使得公式 (13) 的第三项成为常数 $4\sqrt{\frac{1}{n} (\frac{1}{2\alpha} + \ln \frac{2n}{\delta})}$ 。因此, 鲁棒泛化差距被第二项界定, 即权重损失景观平坦度的期望。考虑到优化效率和对期望的有效性, $\mathbb{E}_{\mathbf{u}} [\rho(\mathbf{w} + \mathbf{u})] \leq \max_{\mathbf{u}} [\rho(\mathbf{w} + \mathbf{u})]$ 。AWP 精确优化了权重损失景观平坦度的最差情况 $\{\max_{\mathbf{u}} [\rho(\mathbf{w} + \mathbf{u})] - \rho(\mathbf{w})\}$ 来控制上述 PAC-Bayes 界, 从而从理论上解释了 AWP 的有效性。

4 基于 AWP 的改进

对抗权重扰动通过在对抗训练过程中显式引入权重扰动, 有效平坦化了权重损失景观, 从而提升模型的对抗鲁棒性。尽管原始 AWP 已在多种基准实验中取得了显著效果, 但其权重扰动策略仍存在一定的设计空间。本章在复现原始 AWP 方法的基础上, 围绕权重扰动的施加方式与调度策略展开探索性改进, 主要包括分层对抗权重扰动 (Layer-wise AWP) 与渐进式对抗权重扰动 (Progressive AWP) 两种方案。

4.1 分层对抗权重扰动

在原始 AWP 中, 权重扰动的可行域由式 (8) 统一约束, 其中所有网络层共享同一扰动系数 γ 。该设定隐含了一个重要假设: 不同网络层对权重扰动的敏感性是相同的。

然而, 在深度神经网络中, 不同层在参数规模、梯度分布以及对鲁棒性的贡献方面往往存在显著差

异。浅层通常负责低级特征提取，对输入扰动和权重扰动较为敏感；而深层更多影响决策边界，其权重损失景观的形态也可能存在差异。因此，对所有层施加统一强度的权重扰动，可能无法精细刻画权重损失景观在不同子空间中的变化特性。为刻画层间差异，本文将模型参数按层分解为：

$$\mathbf{w} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_L\} \quad (14)$$

相应地，权重扰动也被分解为：

$$\mathbf{v} = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_L\} \quad (15)$$

在 Layer-wise AWP 中，式 (7) 中的权重扰动最大化问题被扩展为：

$$\max_{\mathbf{v} \in \mathcal{V}_{\text{layer}}} \rho(\mathbf{w} + \mathbf{v}), \quad \mathcal{V}_{\text{layer}} = \{\mathbf{v} \mid \|\mathbf{v}_l\| \leq \gamma_l \|\mathbf{w}_l\|, \forall l\} \quad (16)$$

当 $\gamma_l = \gamma$ 对所有层成立时，上式严格退化为原始 AWP。因此，Layer-wise AWP 可以被视为对原式 (8) 的分层放松。

与权重损失景观平坦性的关系：结合式 (6)，Layer-wise AWP 实际优化的目标可写为：

$$\min_{\mathbf{w}} \left[\max_{\mathbf{v} \in \mathcal{V}_{\text{layer}}} \rho(\mathbf{w} + \mathbf{v}) - \rho(\mathbf{w}) \right] \quad (17)$$

与原始 AWP 相比，该方法将权重空间中的扰动邻域从“统一球形区域”扩展为“按层约束的复合区域”。从几何角度看，这相当于在不同层对应的子空间中施加不同尺度的扰动半径，从而在更细粒度上平坦化权重损失景观。Layer-wise AWP 并未改变 AWP 对“最坏情况权重扰动”的优化目标，而是通过引入分层扰动系数，使权重损失景观的正则化更贴合网络的结构特性。即使在本文实验中该方法未带来显著性能提升，其理论形式仍为后续分析不同层对鲁棒泛化差距的影响提供了合理基础。

4.2 渐进式对抗权重扰动

原始 AWP 在整个训练过程中始终采用固定的扰动强度 γ ，即默认模型在训练早期与训练后期对权重扰动的承受能力是相同的。然而，在实际训练过程中，模型参数分布与权重损失景观会随时间动态变化：训练初期，模型尚未收敛，权重损失景观通常较为陡峭；训练后期，模型逐渐进入局部极小值区域，平坦性正则化更为关键。在此背景下，过早施加较强的权重扰动，可能干扰模型对基本判别结构的学习。为此，本文引入一个随训练轮数变化的扰动调度函数 $\gamma(t)$ ，将式 (8) 改写为：

$$\|\mathbf{v}_l\| \leq \gamma(t) \|\mathbf{w}_l\| \quad (18)$$

其中 $\gamma(t)$ 可采用如下分段形式：

$$\gamma(t) = \begin{cases} 0, & t < T_{\text{warmup}}, \\ \gamma_{\text{max}}, & t \geq T_{\text{warmup}}, \end{cases} \quad (19)$$

当 $\gamma(t) \equiv \gamma$ 时，该方法严格退化为原始 AWP。

从 PAC-Bayes 泛化界 (式 (12)、(13)) 的角度看，鲁棒泛化差距主要由权重损失景观平坦度项

$\mathbb{E}_{\mathbf{u}}[\rho(\mathbf{w} + \mathbf{u})] - \rho(\mathbf{w})$ 所控制。Progressive AWP 并未改变该界的形式，而是通过时间调度的方式，在模型趋于稳定后再逐步强化对该项的约束。

因此，Progressive AWP 可以被视为一种权重空间中的课程正则化：模型先学习基本判别能力，再通过最坏情况权重扰动抑制尖锐极小值。Progressive AWP 在保持 AWP 理论基础不变的前提下，引入了训练时间维度上的灵活性。尽管其在本文实验中未能显著提升最终鲁棒精度，但在理论上有助于缓解训练初期的不稳定问题，并提高优化过程的可控性。

从统一视角来看，本文提出的两种改进方法分别对应于对 AWP 权重扰动机制的不同扩展方向：Layer-wise AWP 在空间维度上细化了式 (8) 中的扰动约束；Progressive AWP 在时间维度上对扰动强度进行调度。二者均未改变 AWP 在式 (6) 中“通过最坏情况权重扰动平坦化权重损失景观”的核心目标，而是在不同维度上探索其潜在的改进空间。

5 实验

本章基于 CIFAR-10 数据集，对对抗权重扰动与所提出的分层对抗权重扰动和渐进式对抗权重扰动方法在标准对抗训练 (AT) 框架中的有效性进行全面评估。实验旨在验证这些改进策略在提升模型对抗鲁棒性方面的作用，同时保持较高的干净准确率。评估采用基准数据集，并使用 PGD 攻击和 AutoAttack 等标准协议与基线 AT 及原始 AWP 进行比较。所有实现基于提供的代码库，包括对 AWP 模块的分层扰动缩放和渐进调度修改。实验参考 [1] 的原始 AWP 论文设置，但为适应计算资源限制，本文将训练周期缩短至 30 个 epoch，并使用 PGD-5 攻击代替 PGD-10 或 PGD-20。

5.1 实验设置

1) 数据集与模型架构：

实验在 CIFAR-10 数据集上进行，该数据集是图像分类任务的标准基准，包含 50,000 张训练图像和 10,000 张测试图像，涵盖 10 个类别，图像尺寸为 32×32 像素，三通道彩色。训练图像预处理包括填充 4 像素、随机裁剪至 32×32 及水平翻转，如

train_cifar10.py 脚本所示。归一化使用数据集均值 ($\mu = [0.4914, 0.4822, 0.4465]$) 和标准差 ($\sigma = [0.2471, 0.2435, 0.2616]$)。

主要模型架构为 PreActResNet-18, 该 ResNet 变体针对对抗训练优化, 具有性能与计算效率的良好平衡。该选择符合鲁棒性研究中的常见实践。

2) 训练配置:

训练采用随机梯度下降 (SGD), 动量为 0.9, 权重衰减为 5×10^{-4} 。学习率采用余弦退火调度, 从 0.1 起始, 在 30 个 epoch 内衰减至近零。训练批次大小为 64, 测试为 128。

对抗样本通过投影梯度下降 (PGD) 生成, 训练与测试均使用 5 次迭代 (记为 PGD-5), ℓ_∞ 扰动预算 $\epsilon = 8/255$, 步长 $\alpha = 2/255$ 。AWP 模块 (如 awp.py 定义) 在指定预热期后引入权重扰动, γ 默认为 0.01 (实验中测试 0.005 以优化)。在 Layer-wise AWP 中, 扰动系数分层: 分类头 ('fc'或'linear'层) 为 1.0, 高层特征 ('layer3'或'layer4') 为 0.75, 低层为 0.5。在 Progressive AWP 中, γ 从 0 渐进线性增加至目标值, 以缓解初期不稳定。

评估四种主要配置: 基线 AT: 纯对抗训练, 无 AWP (--no-awp 标志); 原始 AWP: 标准双重扰动, 均匀权重扰动; Layer-wise AWP: 分层权重扰动; Progressive AWP: 渐进式权重扰动调度。

训练日志记录于代码包 experiments 部分, 详述每个 epoch 的指标, 多轮跑次用于参数调优。

3) 评估指标与攻击:

干净准确率: 未扰动测试图像准确率。

鲁棒准确率: 对抗扰动下准确率, 主要为 PGD-5。

AutoAttack 鲁棒性: 使用 AutoAttack 套件 (eval.py 所示) 全面评估, 包括 APGD-CE、APGD-DLR、FAB 和 Square 攻击, ℓ_∞ 范数 $\epsilon = 8/255$ 。

评估覆盖全部 10,000 测试样本, AutoAttack 批次大小为 200。结果聚焦最终 epoch, 并报告多轮跑次的平均/最佳值。

5.2 实验结果




图 1 不同配置下测试干净准确率随训练轮次的变化




图 2 不同配置下测试鲁棒准确率随训练轮次的变化

Table 1 Accuracy of Different Methods on Clean and PGD-5 Adversarial Examples

表 1 不同方法的干净样本和 PGD-5 对抗样本准确率

方法	Test Clean	PGD-5
基线 AT	83.43	56.56
原始 AWP ($\gamma=0.01$)	76.24	55.18
原始 AWP ($\gamma=0.005$)	80.22	57.24
Layer-wise AWP	80.30	57.13
Progressive AWP	80.20	56.84

图 1 展示了不同对抗权重扰动 (AWP) 方法在训练过程中干净样本准确率随训练轮次的变化。图中呈现的五条曲线分别代表了以下五种训练配置: 基线 AT (蓝色曲线)、原始 AWP ($\gamma=0.01$) (红色曲线)、原始 AWP ($\gamma=0.005$) (绿色曲线)、Layer-wise AWP (橙色曲线)、Progressive AWP (紫色曲线)。

从图中可以看出, 基线 AT 在干净样本准确率上的表现显著优于 AWP 方法, 其准确率随着训练轮次的增加稳步提升, 并且最终保持在较高水平。这一结果表明, 标准对抗训练未引入扰动, 因此能够维持较高的干净准确率。

与基线 AT (83.43%) 相比, AWP 方法在干净样本上的准确率普遍下降, 尤其是较大的扰动 ($\gamma=0.01$) 对干净准确率的影响较为明显。原始 AWP ($\gamma=0.01$) 的干净准确率下降至 76.24%, 而原始 AWP ($\gamma=0.005$) (80.22%) 和 Progressive AWP (80.20%) 则在引入扰动的同时, 能够有效地维持较为稳定的干净准确率, 尽管其准确率较基线 AT 有所下降, 但相较于较大扰动的 AWP, 其干净样本的损失更为有限。

Progressive AWP 表现出了较好的平衡, 尽管其引入了逐步增加的扰动, 但干净样本的准确率变化较为平滑, 这表明该方法通过调节扰动强度避免了过早施加强扰动导致的训练不稳定性。Layer-wise AWP 则通过在网络的不同层次施加扰动, 展现了较为稳定的训练过程, 尽管干净准确率有所下降, 但相较于其他

Table 2: Robustness Performance of Different Adversarial Training Methods under AutoAttack Evaluation

表 2 不同对抗训练方法在 AutoAttack 评估下的鲁棒性表现

方法	Test Clean	APGD-CE→	APGD-T→	FAB-T→	Square→	Final robust accuracy
基线 AT	83.42	47.27	44.14	44.14	44.14	44.14
原始 AWP ($\gamma=0.005$)	80.22	50.18	46.39	46.39	46.39	46.39
Layer-wise AWP	80.13	50.05	46.20	46.20	46.20	46.20
Progressive AWP	80.20	49.85	46.24	46.23	46.23	46.23

AWP 方法，其干净准确率的损失较小，且在训练过程中保持了较好的稳定性。

图 2 展示了不同 AWP 方法在训练过程中对抗样本的准确率随训练轮次的变化，曲线颜色与图 1 对应。从图中可以看到，基线 AT 方法在训练的早期能够迅速提升对抗鲁棒性，但随着训练轮次的增加，其鲁棒准确率的提升趋于平缓，最终鲁棒准确率为 56.56%，这反映出标准对抗训练在提升模型对抗鲁棒性方面的有限性。

相比之下，原始 AWP ($\gamma=0.005$) 显著提高了鲁棒准确率，尤其是在训练初期，鲁棒准确率增长较快，并且在训练过程中保持较高的稳定性。原始 AWP ($\gamma=0.005$) 的 PGD-5 鲁棒准确率为 57.24%，超过了基线 AT。这表明，较小的扰动强度能够有效地提升对抗样本的鲁棒性，同时减少扰动过大对训练稳定性的负面影响。与此不同，原始 AWP ($\gamma=0.01$) 的 PGD-5 鲁棒准确率为 55.18%，虽然在初期展现了较为快速的鲁棒性提升，但较大的扰动导致鲁棒准确率的提升逐渐减缓，最终鲁棒准确率低于原始 AWP ($\gamma=0.005$)。这表明，较大的扰动可能在训练过程中引起不稳定，从而限制了其对抗鲁棒性的持续提升。

在不同的 AWP 变体中，Layer-wise AWP 和 Progressive AWP 展现了较为平稳的增长趋势，尤其是 Progressive AWP。通过逐步增加扰动强度，Progressive AWP 能够持续推动对抗鲁棒性提升，且鲁棒准确率随着训练轮次的增加稳定上升，最终超越了基线 AT 和较大扰动的 AWP 方法。Progressive AWP 能够精细控制扰动强度，避免了较早施加强扰动导致的训练不稳定，从而保持了较好的训练稳定性，并实现了对抗鲁棒性的显著提升。

5.3 AutoAttack 评估

表 2 记录了不同对抗训练方法在 AutoAttack 评估下的鲁棒性表现，包括对抗样本的准确率在多个标准攻击下的变化。AutoAttack 是一个综合的攻击评估工具，涵盖了 APGD-CE、APGD-T、FAB-T 和 Square 等多种攻击方式，对模型的鲁棒性进行了全面评估。攻击顺序为 APGD-CE $\rightarrow$ APGD-T $\rightarrow$ FAB-T $\rightarrow$

Square。表中数据对应模型遭受相应攻击后的鲁棒准确率。

根据表 2 结果，可以观察到，基线 AT（标准对抗训练）在对抗样本的鲁棒性上表现较弱。尽管其干净样本准确率较高（83.42%），但在各类对抗攻击（APGD-CE、APGD-T、FAB-T 和 Square）后，鲁棒准确率仅为 44.14%。这表明，基线 AT 虽然能够提高模型对抗样本的鲁棒性，但在应对复杂的对抗攻击时，其防御效果相对有限。

相比之下，原始 AWP ($\gamma=0.005$) 显著提高了对抗样本的鲁棒性。该方法最终鲁棒准确率为 46.39%，大幅超越了基线 AT。这表明，较小的扰动能够有效提高模型对抗鲁棒性，在面对 PGD 和 AutoAttack 攻击时，AWP 方法展现了较强的防御能力。

Layer-wise AWP 和 Progressive AWP 展现了较为平稳的鲁棒性提升，在 APGD-CE、APGD-T 等攻击下保持较高的鲁棒准确率。Progressive AWP 最终的鲁棒准确率为 46.23%，与原始 AWP ($\gamma=0.005$) 相当，展现了较好的鲁棒性提升效果。

总体而言，原始 AWP ($\gamma=0.005$) 在提升对抗鲁棒性方面表现最为突出，尤其是在面对多种类型的对抗攻击时，它能够显著提高鲁棒准确率。Progressive AWP 和 Layer-wise AWP 也展现了不错的鲁棒性提升。所有 AWP 方法相较于基线 AT，都显著提高了模型的鲁棒性，证明 AWP 框架在对抗训练中的有效性。

5.4 改进方法未带来显著提升的原因分析

尽管分层对抗权重扰动与渐进式对抗权重扰动在理论上对原始 AWP 的权重扰动机制进行了合理扩展，但在本文的实验设置下，这两种改进方法在鲁棒性能指标上均未显著优于原始 AWP。对此现象，本文结合 AWP 的优化目标与理论分析，从以下几个方面进行讨论：

1) 原始 AWP 对权重损失景观的正则化可能已接近饱和

从式 (6) 可以看出，AWP 通过最小化 $\max_{\mathbf{v} \in \mathcal{V}} [\rho(\mathbf{w} + \mathbf{v}) - \rho(\mathbf{w})]$ 来显式约束权重损失景

观的平坦度。该目标本质上是在权重空间中施加近似最坏情况的全局扰动约束。在当前实验配置（数据集规模、模型容量以及扰动强度 γ 的设定）下，原始 AWP 可能已经能够有效抑制权重空间中的尖锐极小值，使权重损失景观达到相对平坦的状态。在这种情况下，对扰动形式进行进一步细化（如分层约束或时间调度）未必能够继续显著降低 $\rho(\mathbf{w} + \mathbf{v}) - \rho(\mathbf{w})$ ，从而导致鲁棒性能提升趋于饱和。

2) 分层扰动可能削弱了“全局最坏方向”的约束效果

Layer-wise AWP 通过将扰动可行域从统一约束 $\|\mathbf{v}_l\| \leq \gamma \|\mathbf{w}_l\|$ 扩展为按层独立约束 $\|\mathbf{v}_l\| \leq \gamma_l \|\mathbf{w}_l\|$ ，以期更精细地刻画不同层权重损失景观的敏感性。

然而，从优化角度看，原始 AWP 在式 (7) 中寻求的是整个权重空间中的最坏情况扰动方向。分层约束在一定程度上将原本统一的扰动空间拆分为多个子空间，可能使最终得到的扰动方向偏离全局最陡峭的上升方向，从而削弱了对 $\max_{\mathbf{v}} \rho(\mathbf{w} + \mathbf{v})$ 的近似能力。这种“扰动空间解耦”效应，可能解释了 Layer-wise AWP 未能带来进一步鲁棒性提升的现象。

3) 渐进式扰动调度与对抗训练动态可能存在耦合冲突

Progressive AWP 通过引入时间相关扰动系数 $\gamma(t)$ ，对式 (8) 中的扰动强度进行调度，以缓解训练早期权重扰动对优化稳定性的影响。该策略在工程层面具有合理动机，与学习率 warm-up 或 curriculum adversarial training 具有相似直觉。

然而，对抗训练本身已经涉及输入扰动强度、模型收敛速度以及学习率调度等多个动态因素。在此基础上额外引入权重扰动调度，可能与现有训练动态产生耦合效应，使最终模型在训练后期所达到的权重损失景观形态与原始 AWP 相近，从而导致最终鲁棒精度差异不明显。

4) 实验设置规模限制改进方法潜在优势的体现

因资源有限，本文的实验主要基于 CIFAR-10 数据集和中等规模网络结构展开。在该设置下，模型容量与任务复杂度相对有限，权重损失景观的形态可能较为简单。一些更细粒度的权重扰动策略，其潜在优势可能需要在更大规模数据集或更深层网络结构中才能充分体现。因此，Layer-wise AWP 与 Progressive AWP 在当前实验条件下未能显著优于原始 AWP，并不意味着其理论动机不成立，而可能与实验规模和任务复杂度有关。

5) 与理论分析的一致性

从理论角度看，PAC-Bayes 泛化界（式 (12) - (13)）表明，鲁棒泛化差距主要由权重损失景观平坦度的期望所控制。本文提出的两种改进方法并未改变该界的基本形式，而只是通过不同方式对权重扰动约束进行调整。因此，当原始 AWP 已能够有效降低该项时，进一步改进所带来的收益可能有限。

综上所述，本文提出的 Layer-wise AWP 与 Progressive AWP 在理论上均为对原始 AWP 的合理扩展，但在当前实验配置下，其性能未能显著超越原始方法。这一结果表明，AWP 的核心优势主要来源于其对权重损失景观进行全局最坏情况正则化的能力，而非权重扰动形式或调度策略的复杂化。上述分析也为未来在更大规模任务中进一步探索权重扰动策略提供了参考。

结论

本文系统复现了 Wu 等人^[1]提出的对抗权重扰动方法，并在标准对抗训练框架下验证了其在提升深度神经网络对抗鲁棒性方面的有效性。AWP 通过引入权重空间的最坏情况扰动，与传统的输入扰动形成双重扰动机制，显式地正则化了权重损失景观的平坦度，从而有效缩小了鲁棒泛化差距。这一机制不仅具有坚实的理论基础（如 PAC-Bayes 泛化界），而且在实际训练中几乎不增加额外计算开销，具有较高的通用性和可集成性。

在此基础上，本文进一步探索了两种基于 AWP 的改进策略：分层对抗权重扰动和渐进式对抗权重扰动。Layer-wise AWP 通过对网络不同层施加差异化的扰动约束，试图在权重子空间中实现更精细的景观平坦化；Progressive AWP 则通过随训练进程逐步增强扰动强度，旨在缓解训练早期可能的不稳定性。在 CIFAR-10 数据集和 PreActResNet-18 模型上的实验表明，这两种改进方法在训练稳定性方面表现良好，干净准确率与鲁棒准确率均与原始 AWP 相当，但在当前实验设置（包括较短的训练周期和中等规模任务）下，未能显著超越原始 AWP 的鲁棒性能。这一结果提示，原始 AWP 对权重损失景观的全局最坏情况正则化已较为充分，进一步的扰动细化或调度调整在有限规模任务中带来的增益较为有限，其潜在优势可能需要在更大规模的数据集、更复杂的模型结构或更长的训练周期中才能充分体现。

总体而言，本文的工作验证了 AWP 作为一种简单而强大的对抗训练增强手段的核心价值，同时为权重扰动策略的进一步优化提供了实证参考。

参 考 文 献

- [1] Wu Dongxian, Xia Shu-Tao, Wang Yisen. Adversarial weight perturbation helps robust generalization[C]//Advances in Neural Information Processing Systems. Red Hook, NY: Curran Associates, Inc., 2020.
- [2] Ian J Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. In ICLR, 2015.
- [3] Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, and Adrian Vladu. Towards deep learning models resistant to adversarial attacks. In ICML, 2018.
- [4] Behnam Neyshabur, Srinadh Bhojanapalli, David McAllester, and Nati Srebro. Exploring generalization in deep learning. In NeurIPS, 2017.
- [5] Vinay Uday Prabhu, Dian Ang Yap, Joyce Xu, and John Whaley. Understanding adversarial robustness through loss landscape geometries. arXiv preprint arXiv:1907.09061, 2019.
- [6] Fuxun Yu, Chenchen Liu, Yanzhi Wang, Liang Zhao, and Xiang Chen. Interpreting adversarial robustness: A view from decision surface in input space. arXiv preprint arXiv:1810.00144, 2018.
- [7] Zhezhi He, Adnan Siraj Rakin, and Deliang Fan. Parametric noise injection: Trainable randomness to improve deep neural network robustness against adversarial attack. In CVPR, 2019.
- [8] Anish Athalye, Nicholas Carlini, and David Wagner. Obfuscated gradients give a false sense of security: Circumventing defenses to adversarial examples. In ICML, 2018.
- [9] Hongyang Zhang, Yaodong Yu, Jiantao Jiao, Eric P. Xing, Laurent El Ghaoui, and Michael I. Jordan. Theoretically principled trade-off between robustness and accuracy. In ICML, 2019.
- [10] Yisen Wang, Difan Zou, Jinfeng Yi, James Bailey, Xingjun Ma, and Quanquan Gu. Improving adversarial robustness requires revisiting misclassified examples. In ICLR, 2020.
- [11] Yair Carmon, Aditi Raghunathan, Ludwig Schmidt, John C Duchi, and Percy S Liang. Unlabeled data improves adversarial robustness. In NeurIPS, 2019.